

فصل ۱۰: یادگیری عمیق^۱

مقدمه

یادگیری عمیق یک موضوع اساسی در تحقیقات یادگیری ماشین^۲ و هوش مصنوعی^۳ معاصر است. در مرکز آن، شبکه‌های عصبی^۴ قرار دارند که در اواخر دهه ۱۹۸۰ محبوبیت پیدا کردند. در ابتدا، شبکه‌های عصبی هیجان زیادی ایجاد کردند و منجر به برگزاری کنفرانس‌های سالانه سیستم‌های پردازش اطلاعات عصبی (NeurIPS) شدند. با این حال، آنها با مرحله‌ای از تحلیل و ترکیب انتقادی مواجه شدند و با بهبود الگوریتم‌ها و روش‌شناسی، روش‌های دیگری مانند ماشین بردار پشتیبان^۵، تقویت‌سازی^۶ و جنگل‌های تصادفی^۷ به دلیل سهولت استفاده و عملکرد بهتر در برخی وظایف، شبکه‌های عصبی را تحت الشعاع قرار دادند.

با این وجود، گروهی از محققان به پیشرفت شبکه‌های عصبی ادامه دادند و از معماری‌های بزرگتر و مجموعه داده‌های بزرگتر بهره بردند. پس از سال ۲۰۱۰، شبکه‌های عصبی تحت عنوان یادگیری عمیق دوباره ظاهر شدند و با استفاده از معماری‌های جدید به موفقیت‌های چشمگیری در زمینه‌های تخصصی مانند طبقه‌بندی تصویر و ویدیو و مدل‌سازی گفتار و متن دست یافتند. دیجیتالی شدن گسترده در زمینه‌های مختلف، عاملی مهم در این پیشرفت‌ها بوده است. این فصل به اصول شبکه‌های عصبی و یادگیری عمیق پرداخته و مدل‌های خاصی مانند شبکه‌های عصبی کانولوشنی^۸ (CNN) برای طبقه‌بندی تصویر و شبکه‌های عصبی بازگشتی^۹ (RNN) برای تحلیل سری‌های زمانی را بررسی می‌کند. پکیج torch در پایتون و کتابخانه‌های مرتبط برای اهداف نمایشی استفاده می‌شوند.

^۱ Deep Learning

^۲ Machine Learning

^۳ Artificial Intelligence

^۴ Neural Networks

^۵ SVM(Support Vector Machine)

^۶ Boosting

^۷ Random Forests

^۸ Convolutional Neural Network

^۹ Recurrent Neural Network

۱۰.۱ شبکه‌های عصبی تک‌لایه^۱

شبکه‌های عصبی بردار ورودی p متغیر $X = (X_1, X_2, \dots, X_p)$ را به یک تابع غیرخطی $f(X)$ تبدیل می‌کنند تا پاسخ Y را پیش‌بینی کنند. برخلاف مدل‌های غیرخطی قبلی، شبکه‌های عصبی ساختاری متمایز دارند که شامل نورون‌های متصل به یکدیگر است و در لایه‌ها سازماندهی شده‌اند. یک شبکه عصبی ساده متشکل از یک لایه ورودی، یک لایه پنهان^۲ و یک لایه خروجی است. لایه پنهان تبدیل‌های غیرخطی روی ترکیبات خطی ورودی‌ها انجام می‌دهد و فعال‌سازی^۳های $A_k = h_k(X)$ را تولید می‌کند. این فعال‌سازی‌ها سپس در لایه خروجی برای ایجاد پیش‌بینی نهایی $f(X)$ استفاده می‌شوند.

واحد اساسی یک شبکه عصبی یک نورون^۴ است که مجموع وزنی ورودی‌هایش را محاسبه کرده و آن را از طریق یک تابع فعال‌سازی غیرخطی عبور می‌دهد. توابع فعال‌سازی رایج شامل سیگموئید^۵، تانژانت هیپربولیک^۶ و واحد خطی اصلاح شده^۷ (ReLU) هستند. خروجی شبکه یک مجموع وزنی از فعال‌سازی‌های لایه پنهان است که پیش‌بینی را برای یک ورودی خاص فراهم می‌کند. به طور ریاضی، شبکه به این صورت نمایندگی می‌شود:

$$f(X) = \beta_0 + \sum_{k=1}^K \beta_k h_k(X) = \beta_0 + \sum_{k=1}^K \beta_k g(w_{k0} + \sum_{j=1}^p w_{kj} X_j)$$

آموزش یک شبکه عصبی شامل یافتن وزن‌ها و بایاس^۸های بهینه است که خطای پیش‌بینی را به حداقل می‌رساند. این کار معمولاً با استفاده از روش‌های بهینه‌سازی مبتنی بر گرادیان، مانند نزول گرادیان^۹، که وزن‌ها را به صورت تکراری براساس گرادیان خطا تنظیم می‌کند، انجام می‌شود. الگوریتم کلیدی در آموزش شبکه‌های عصبی، انتشار به عقب^{۱۰} است که گرادیان تابع خطا را نسبت به هر وزن با اعمال قانون زنجیره‌ای حسابان محاسبه می‌کند و امکان محاسبه کارآمد گرادیان‌ها برای همه وزن‌ها در شبکه را فراهم می‌کند.

¹ Single-Layer Neural Network

² Hidden Layer

³ Activation

⁴ Neuron

⁵ Sigmoid

⁶ Hyperbolic Tangent

⁷ ReLU (Rectified Linear Unit)

⁸ Bias

⁹ Gradient Descent

¹⁰ Backpropagation

۱۰.۲ شبکه‌های عصبی چندلایه^۱

شبکه‌های عصبی چندلایه، یا شبکه‌های عصبی عمیق، مفهوم را با افزودن لایه‌های پنهان بیشتر بین لایه ورودی و خروجی گسترش می‌دهند. هر لایه پنهان شامل واحدهایی است که تبدیل‌های غیرخطی را بر روی ورودی‌های لایه قبلی انجام می‌دهند. این ساختار سلسله‌مراتبی به شبکه امکان می‌دهد الگوهای پیچیده را در داده‌ها بیاموزد و آن را قادر می‌سازد وظایف پیچیده‌تری را نسبت به شبکه‌های تک‌لایه انجام دهد.

معماری یک شبکه عصبی عمیق می‌تواند به طور قابل‌توجهی متفاوت باشد، با تعداد مختلف لایه‌ها و واحدها در هر لایه. انتخاب معماری، از جمله تعداد لایه‌ها و تعداد واحدها در هر لایه، جنبه مهمی از طراحی مدل است و می‌تواند به طور قابل‌توجهی بر عملکرد تاثیر بگذارد. در عمل، طراحی یک شبکه عصبی عمیق شامل تعادلی بین پیچیدگی مدل و منابع محاسباتی است، زیرا شبکه‌های عمیق‌تر نیاز به توان محاسباتی بیشتری دارند و در صورت عدم تنظیم مناسب ممکن است به بیش‌برازش^۲ دچار شوند.

آموزش شبکه‌های عصبی عمیق دشوارتر از آموزش شبکه‌های سطحی است به دلیل مسائلی مانند ناپدید شدن و انفجار گرادیان‌ها^۳ که می‌توانند مانع از همگرایی الگوریتم بهینه‌سازی شوند. تکنیک‌های مختلفی برای مقابله با این مسائل توسعه یافته‌اند، مانند الگوریتم‌های پیشرفته بهینه‌سازی (مانند Adam، RMSprop) و استراتژی‌های اولیه‌سازی^۴ (مانند Xavier) و روش‌های تنظیم^۵ (مانند دراپ‌اوت^۶، نرمال‌سازی دسته‌ای^۷). این تکنیک‌ها به تثبیت فرآیند آموزش و بهبود توانایی شبکه در تعمیم به داده‌های جدید کمک می‌کنند.

^۱ Multi-Layer Neural Network

^۲ Overfitting

^۳ Vanishing and Exploding Gradients

^۴ Initialization

^۵ Regularization

^۶ Dropout

^۷ Batch Normalization

۱۰.۳ شبکه‌های عصبی کانولوشنی (CNNs)

شبکه‌های عصبی کانولوشنی (CNNs) برای پردازش داده‌هایی با توپولوژی شبکه‌ای، مانند تصاویر، تخصص یافته‌اند. آنها شامل لایه‌های کانولوشنی هستند که فیلترها را برای استخراج ویژگی‌ها اعمال می‌کنند، لایه‌های پولینگ^۱ که ابعاد را کاهش می‌دهند و لایه‌های کاملاً متصل^۲ برای طبقه‌بندی^۳. مزیت اصلی CNNs در توانایی آنها در یادگیری سلسله‌مراتب فضایی ویژگی‌ها از داده‌های ورودی است که آنها را برای وظایف مرتبط با تصویر بسیار موثر می‌سازد.

۱. **لایه‌های کانولوشنی:** لایه‌های کانولوشنی مجموعه‌ای از فیلترهای قابل یادگیری را بر روی داده‌های ورودی اعمال می‌کنند و عملیات کانولوشن را انجام می‌دهند که فیلتر را روی ورودی حرکت داده و ضرب داخلی^۴ را در هر مکان محاسبه می‌کند. این عملیات الگوها و ویژگی‌های محلی، مانند لبه‌ها^۵ و بافت‌ها^۶ را که سپس به عنوان ورودی برای لایه‌های بعدی استفاده می‌شوند، ضبط می‌کند.

۲. **لایه‌های پولینگ:** لایه‌های پولینگ ابعاد فضایی داده‌ها را با انجام عملیات‌هایی مانند Max-Pooling یا Average-Pooling کاهش می‌دهند. این باعث کاهش بار می‌شود.

۳. **معماری^۷:** یک معماری CNN معمولی شامل لایه‌های کانولوشنی و پولینگ متناوب، به دنبال یک یا چند لایه کاملاً متصل است. لایه‌های کانولوشنی و پولینگ ویژگی‌های سلسله‌مراتبی را از ورودی استخراج می‌کنند، در حالی که لایه‌های کاملاً متصل از این ویژگی‌ها برای انجام طبقه‌بندی یا رگرسیون^۸ استفاده می‌کنند.

۴. **افزایش داده‌ها^۹:** برای بهبود توانایی تعمیم شبکه، تکنیک‌های افزایش داده‌ها مانند چرخش^{۱۰}، مقیاس‌بندی^{۱۱} و وارونه کردن^{۱۲} برای افزایش مصنوعی اندازه مجموعه داده

¹ Pooling

² Fully Connected

³ Classification

⁴ Dot Product

⁵ Edges

⁶ Textures

⁷ Architecture

⁸ Regression

⁹ Data Augmentation

¹⁰ Rotation

¹¹ Scaling

¹² Flipping

آموزشی^۱ استفاده می‌شوند. این به جلوگیری از بیش‌برازش کمک کرده و شبکه را نسبت به تغییرات در داده‌های ورودی قوی‌تر می‌سازد.

مدل‌های CNN از پیش‌آموزش دیده^۲ که بر روی مجموعه داده‌های بزرگ مانند ImageNet آموزش دیده‌اند، می‌توانند برای وظایف خاص تنظیم مجدد^۳ شوند و این باعث بهبود قابل‌توجه عملکرد می‌شود. تنظیم مجدد شامل شروع شبکه با وزن‌های یک مدل پیش‌آموزش دیده و سپس آموزش آن بر روی مجموعه داده هدف است که به شبکه امکان می‌دهد از ویژگی‌های یاد گرفته شده استفاده کند و در عین حال به وظیفه جدید سازگار شود.

۱۰.۴ طبقه‌بندی اسناد^۴

طبقه‌بندی سند شامل دسته‌بندی اسناد متنی به کلاس‌های از پیش تعریف‌شده است. شبکه‌های عصبی، به‌ویژه شبکه‌های عصبی بازگشتی (RNNs) و انواع دیگر آن‌ها، به دلیل توانایی آن‌ها در ثبت وابستگی‌های ترتیبی در متن برای این وظیفه موثر هستند. داده‌های متنی چالش‌های منحصر به فردی مانند دنباله‌های با طول متغیر و نیاز به پردازش مبتنی بر بافت را ارائه می‌دهند که شبکه‌های عصبی به‌طور موثری به آن‌ها پاسخ می‌دهند.

۱. **مدل‌های ترتیبی:** RNN‌ها دنباله‌های کلمات را با نگه‌داشتن حالت‌های پنهانی که اطلاعات مراحل زمانی قبلی را ثبت می‌کنند، پردازش می‌کنند. این به شبکه امکان می‌دهد تا بر اساس موقعیت کلمات در دنباله، بافت و معنای کلمات را درک کند. انواع گوناگونی از شبکه عصبی مانند حافظه بلندمدت کوتاه (LSTM) و واحد بازگشتی دارای دروازه (GRU) توانایی شبکه را برای ثبت وابستگی‌های بلندمدت افزایش می‌دهند و مشکلاتی مانند ناپدید شدن گرادیان‌ها را کاهش می‌دهند.

¹ Training Set

² Pretrained

³ Fine-tuned

⁴ Document Classification

۲. کاربردها: طبقه‌بندی سند شامل طیف گسترده‌ای از وظایف از جمله تحلیل احساسات^۱، تشخیص هرزنامه، طبقه‌بندی موضوع و موارد دیگر می‌شود. شبکه‌های عصبی به طور موفقیت‌آمیزی برای این وظایف استفاده شده‌اند و توانایی خود را در پردازش داده‌های متنی پیچیده و ارائه پیش‌بینی‌های دقیق نشان داده‌اند.

۳. آموزش و ارزیابی: آموزش یک RNN برای طبقه‌بندی سند شامل آماده‌سازی داده‌های متنی (مانند توکن‌سازی^۲، تعبیه^۳)، تعریف معماری شبکه و بهینه‌سازی وزن‌ها با استفاده از الگوریتم‌هایی مانند پس‌انتشار خطا از طریق زمان^۴ (BPTT) می‌شود. معیارهای ارزیابی مانند دقت^۵، صحت^۶، بازخوانی^۷ و امتیاز F1^۸ برای ارزیابی عملکرد مدل در وظایف طبقه‌بندی استفاده می‌شوند.

توانایی RNN‌ها در پردازش داده‌های ترتیبی آن‌ها را برای وظایف طبقه‌بندی سند مناسب می‌سازد، جایی که درک ترتیب و بافت کلمات بسیار مهم است. پیشرفت‌های پردازش زبان طبیعی^۹ (NLP) و دسترسی به مجموعه داده‌های بزرگ متنی قابلیت‌های مدل‌های مبتنی بر RNN را برای تحلیل متن بیشتر تقویت کرده است.

۱۰.۵ شبکه‌های عصبی بازگشتی (RNNs)

شبکه‌های عصبی بازگشتی (RNNs) برای داده‌های ترتیبی طراحی شده‌اند، که آن‌ها را برای وظایفی مانند تحلیل سری‌های زمانی، مدل‌سازی زبان و موارد دیگر مناسب می‌سازد. برخلاف شبکه‌های فید‌فوروارد^{۱۰} سنتی، RNN‌ها حالت پنهانی دارند که اطلاعات مراحل زمانی قبلی را ثبت می‌کند و به آن‌ها امکان می‌دهد وابستگی‌ها و الگوهای زمانی را در داده‌ها یاد بگیرند.

¹ Sentiment Analysis

² Tokenization

³ Embedding

⁴ Backpropagation Through Time

⁵ Accuracy

⁶ Precision

⁷ Recall

⁸ F1-Score

⁹ Natural Language Processing

¹⁰ Feed-Forward

۱. مدل‌های ترتیبی برای طبقه‌بندی سند: RNN‌ها داده‌های متنی را با تکرار از طریق دنباله‌های کلمات پردازش می‌کنند و حالت پنهان را در هر مرحله زمانی به‌روزرسانی می‌کنند تا بافت و معنای متن را منعکس کنند. این پردازش ترتیبی به RNN‌ها امکان می‌دهد تا ورودی‌هایی با طول متغیر را مدیریت کرده و روابط پیچیده بین کلمات را ثبت کنند.

۲. پیش‌بینی سری‌های زمانی: RNN‌ها به ویژه برای پیش‌بینی سری‌های زمانی موثر هستند، جایی که هدف پیش‌بینی مقادیر آینده بر اساس مشاهدات گذشته است. با نگه‌داشتن یک حالت پنهان که در طول زمان تکامل می‌یابد، RNN‌ها می‌توانند روندها، فصلی بودن و سایر الگوهای زمانی را ثبت کرده و پیش‌بینی‌های دقیقی را برای طیف گسترده‌ای از کاربردها ارائه دهند.

۳. چالش‌ها و راه‌حل‌ها: آموزش RNN‌ها می‌تواند از لحاظ محاسباتی فشرده باشد و مستعد مشکلاتی مانند ناپدید شدن و انفجار گرادیان‌ها باشد که فرایند یادگیری را مختل می‌کند. تکنیک‌هایی مانند برش گرادیان^۱، الگوریتم‌های بهینه‌سازی پیشرفته (مثلاً Adam و RMSprop) و نوآوری‌های معماری (مثلاً LSTM و GRU) برای مقابله با این چالش‌ها و بهبود عملکرد RNN‌ها توسعه یافته‌اند.

ابزارهای نرم‌افزاری مدرن مانند TensorFlow و PyTorch پیاده‌سازی و آموزش RNN‌ها را با ارائه انتزاعات سطح بالا و محاسبات کارآمد بر روی شتاب‌دهنده‌های سخت‌افزاری مانند GPU تسهیل می‌کنند. این ابزارها RNN‌ها را برای پژوهشگران و کارورزان قابل دسترس ساخته‌اند و امکان توسعه مدل‌های پیچیده برای تحلیل داده‌های ترتیبی را فراهم کرده‌اند.

¹ Gradient Clipping

۱۰.۶ چه زمانی از یادگیری عمیق استفاده کنیم

یادگیری عمیق عملکرد قابل توجهی در حوزه‌های مختلف، به ویژه طبقه‌بندی تصویر و پردازش زبان طبیعی، نشان داده است. با این حال، همیشه بهترین انتخاب برای هر مشکلی نیست. عواملی مانند اندازه داده، منابع محاسباتی و نیازهای خاص وظیفه باید در تصمیم‌گیری درباره استفاده از یادگیری عمیق مورد توجه قرار گیرند.

۱. مزایا: مدل‌های یادگیری عمیق در وظایفی با مجموعه داده‌های بزرگ و الگوهای پیچیده عملکرد عالی دارند. توانایی آن‌ها در یادگیری خودکار ویژگی‌ها از داده‌های خام آن‌ها را برای وظایفی مانند شناسایی تصویر و گفتار، جایی که مهندسی دستی ویژگی‌ها چالش‌برانگیز است، بسیار مؤثر می‌سازد. علاوه بر این، مدل‌های یادگیری عمیق می‌توانند روابط و وابستگی‌های پیچیده در داده‌ها را ثبت کنند و در بسیاری از کاربردها عملکرد پیشرفته‌ای ارائه دهند.

۲. محدودیت‌ها: با وجود مزایای خود، مدل‌های یادگیری عمیق به توان محاسباتی قابل توجه و مقادیر زیادی داده برچسب‌گذاری شده برای آموزش نیاز دارند. در صورتی که به درستی منظم نشوند، ممکن است مستعد بیش‌برازش شوند و ممکن است نیاز به تنظیم گسترده ابرپارامترها^۱ داشته باشند تا عملکرد بهینه را به دست آورند. برای مجموعه داده‌های کوچک‌تر یا وظایف ساده‌تر، روش‌های سنتی یادگیری ماشین مانند رگرسیون خطی^۲، SVMها و درخت‌های تصمیم^۳ ممکن است مناسب‌تر و کارآمدتر باشند.

۳. ملاحظات عملی: هنگام ارزیابی استفاده از یادگیری عمیق برای یک مشکل خاص، ضروری است که در دسترس بودن داده‌ها، منابع محاسباتی و پیچیدگی وظیفه را در نظر بگیرید. در عمل، ترکیب یادگیری عمیق با روش‌های سنتی و تخصص حوزه اغلب می‌تواند بهترین نتایج را به همراه داشته باشد و نقاط قوت هر رویکرد را به کار گیرد.

یادگیری عمیق نمایانگر یک ابزار قدرتمند در جعبه‌ابزار یادگیری ماشین است، اما کاربرد آن باید با دقت بر اساس مشکل موجود و منابع در دسترس ارزیابی شود. با درک

^۱ Hyperparameters

^۲ Linear Regression

^۳ Decision Trees

نقاط قوت و محدودیت‌های یادگیری عمیق، کارورزان می‌توانند تصمیمات آگاهانه بگیرند و راه‌حل‌های مؤثری برای طیف گسترده‌ای از کاربردها توسعه دهند.

۱۰.۷ برازش یک شبکه عصبی

برازش یک شبکه عصبی شامل چندین مرحله از جمله آماده‌سازی داده، طراحی معماری مدل و آموزش با استفاده از الگوریتم‌های بهینه‌سازی است. فرآیند آموزش به دنبال یافتن وزن‌ها و بایاس‌های بهینه است که خطای پیش‌بینی را در داده‌های آموزشی به حداقل می‌رساند.

۱. **انتشار به عقب:** انتشار به عقب یک الگوریتم کلیدی برای آموزش شبکه‌های عصبی است. این الگوریتم گرادیان تابع خطا^۱ نسبت به هر وزن را با اعمال قانون زنجیره‌ای حساب دیفرانسیل محاسبه می‌کند. سپس گرادیان‌ها برای تنظیم وزن‌ها در جهت کاهش خطا استفاده می‌شوند. این فرآیند تکراری ادامه می‌یابد تا مدل به مجموعه‌ای از وزن‌ها که پیش‌بینی‌های خوبی ارائه می‌دهند، همگرا شود.

۲. **تنظیم^۲ و نزول گرادیان تصادفی^۳ (SGD):** تکنیک‌های تنظیم مانند تنظیم L2 (کاهش وزن) و دراپ‌اوت برای جلوگیری از بیش‌برازش و بهبود توانایی تعمیم شبکه استفاده می‌شوند. نزول گرادیان تصادفی (SGD) و واریانت‌های آن (مانند Adam و RMSprop) الگوریتم‌های بهینه‌سازی معمول هستند که وزن‌ها را بر اساس زیرمجموعه‌ای از داده‌های آموزشی (مینی‌بچ‌ها^۴) به‌روزرسانی می‌کنند و فرآیند آموزش را کارآمدتر و مقیاس‌پذیرتر می‌کنند.

۳. **یادگیری دراپ‌اوت:** دراپ‌اوت یک تکنیک تنظیم است که در طول آموزش به طور تصادفی واحدها (نورون‌ها) را از شبکه حذف می‌کند و از وابستگی بیش از حد شبکه به

^۱ Loss Function

^۲ Regularization

^۳ Stochastic Gradient Descent

^۴ Mini-Batches

هر واحد خاص جلوگیری می‌کند. این کمک می‌کند تا بیش‌برازش کاهش یابد و توانایی تعمیم شبکه به داده‌های جدید بهبود یابد.

۴. تنظیم^۱ شبکه: تنظیم شبکه شامل انتخاب هایپرپارامترهایی مانند نرخ یادگیری^۲، اندازه بچ، تعداد لایه‌ها و تعداد واحدها در هر لایه است. تنظیم دقیق هایپرتنظیم‌ها می‌تواند به طور قابل توجهی بر عملکرد مدل تاثیر بگذارد و اغلب با استفاده از تکنیک‌هایی مانند جستجوی شبکه‌ای یا جستجوی تصادفی انجام می‌شود. اعتبارسنجی متقابل^۳ نیز برای ارزیابی عملکرد مدل و اطمینان از تعمیم‌پذیری آن به داده‌های دیده‌نشده استفاده می‌شود.

آموزش یک شبکه عصبی نیازمند بررسی دقیق این عوامل برای دستیابی به عملکرد بهینه است. با بهره‌گیری از تکنیک‌های بهینه‌سازی پیشرفته، روش‌های منظم‌سازی و تنظیم دقیق هایپرپارامترها، پژوهشگران می‌توانند مدل‌های شبکه عصبی قوی و دقیقی برای وظایف مختلف توسعه دهند.

۱۰.۸ درونیابی و نزول مضاعف(دوگانه)

پدیده نزول مضاعف به مشاهده‌ای اشاره دارد که افزایش پیچیدگی مدل تا حدی می‌تواند ابتدا عملکرد را بدتر کند اما در نهایت آن را بهبود بخشد. این موضوع مفاهیم سنتی توازن بایاس-واریانس^۴ را به چالش می‌کشد و دلالت‌هایی برای درک رفتار یادگیری عمیق دارد.

۱. **توازن بایاس-واریانس سنتی:** در نظریه یادگیری ماشین کلاسیک، پیچیدگی مدل باید با دقت متعادل شود. مدل‌های ساده ممکن است دچار بایاس زیاد و واریانس کم شوند، در حالی که مدل‌های پیچیده‌تر ممکن است واریانس بالا و بایاس کم داشته باشند. هدف یافتن نقطه تعادلی است که عملکرد بهینه روی داده‌های دیده‌نشده را فراهم کند.

¹ Tuning

² Learning Rate

³ Cross-Validation

⁴ Traditional Bias-Variance Tradeoff

۲. **نزول مضاعف:** با این حال، در زمینه یادگیری عمیق، پژوهشگران یک رفتار نزولی مضاعف را مشاهده کرده‌اند که در آن افزایش پیچیدگی مدل ابتدا منجر به افزایش خطا (به دلیل بیش‌برازش) می‌شود، اما افزایش بیشتر در پیچیدگی منجر به کاهش خطا می‌گردد. این پدیده غیرمنتظره نشان می‌دهد که مدل‌های بسیار بزرگ می‌توانند بهتر از مدل‌های با پیچیدگی متوسط تعمیم یابند و دیدگاه‌های سنتی در مورد پیچیدگی مدل را به چالش می‌کشد.

۳. **پیامدها برای یادگیری عمیق:** پدیده نزولی دوگانه (مضاعف) پیامدهای مهمی برای یادگیری عمیق دارد، زیرا به مزایای بالقوه استفاده از مدل‌های با پارامترهای بسیار زیاد اشاره می‌کند. درک این رفتار می‌تواند طراحی مدل و استراتژی‌های آموزشی را آگاه سازد و به کارورزان کمک کند تا از پتانسیل کامل مدل‌های یادگیری عمیق بهره‌برداری کنند.

۱۰.۹ آزمایشگاه: یادگیری عمیق

کاربردها و تمرینات عملی، مفاهیم مطرح شده در فصل را نشان می‌دهند. این آزمایشگاه‌های عملی راهنمایی گام به گام برای پیاده‌سازی و آموزش شبکه‌های عصبی برای وظایف مختلف ارائه می‌دهند و مفاهیم نظری مطرح شده را تقویت می‌کنند.

۱. **شبکه تک‌لایه بر روی داده‌های Hitters:** آزمایشگاه با یک مسئله رگرسیون شروع می‌شود که در آن پیش‌بینی حقوق بازیکنان بیسبال با استفاده از آمار عملکرد از مجموعه داده‌های Hitters انجام می‌شود. یک شبکه عصبی تک‌لایه پیاده‌سازی و آموزش داده می‌شود و فرایند ساخت و برازش یک مدل شبکه عصبی پایه را نشان می‌دهد.

۲. **شبکه چندلایه بر روی داده‌های ارقام MNIST:** آزمایشگاه بعدی بر روی مسئله طبقه‌بندی تمرکز دارد که در آن شناسایی ارقام دست‌نویس از مجموعه داده‌های MNIST انجام می‌شود. یک شبکه عصبی چندلایه پیاده‌سازی می‌شود که استفاده از لایه‌های

مخفی متعدد و تکنیک‌های بهینه‌سازی پیشرفته برای دستیابی به دقت بالا در شناسایی ارقام را نشان می‌دهد.

۳. شبکه‌های عصبی کانولوشنی (CNNs): CNN‌ها برای وظایف طبقه‌بندی تصویر اعمال می‌شوند و اثربخشی آن‌ها در پردازش داده‌های تصویری نشان داده می‌شود. آزمایشگاه شامل پیاده‌سازی لایه‌های کانولوشن و پیمایش، و همچنین تکنیک‌هایی برای بهبود عملکرد از طریق افزایش داده‌ها و یادگیری انتقالی است.

۴. استفاده از مدل‌های CNN از پیش آموزش دیده: این آزمایشگاه استفاده از مدل‌های CNN از پیش آموزش دیده را بررسی می‌کند، که بر روی مجموعه داده‌های بزرگ آموزش داده شده‌اند و می‌توان آن‌ها را برای کاربردهای خاص تنظیم کرد^۱. این رویکرد قدرت یادگیری عمیق را بهره‌برداری می‌کند و در عین حال نیاز به داده‌های آموزشی گسترده و منابع محاسباتی را کاهش می‌دهد.

۵. طبقه‌بندی سند IMDB: آزمایشگاه به تحلیل احساسات با استفاده از RNN‌ها می‌پردازد و داده‌های متنی از مجموعه داده‌های بررسی فیلم‌های IMDB را پردازش می‌کند. پیاده‌سازی RNN‌ها برای طبقه‌بندی متن توانایی آن‌ها در ثبت وابستگی‌های ترتیبی و یافتن در داده‌های متنی را نشان می‌دهد.

۶. شبکه‌های عصبی بازگشتی (RNNs): RNN‌ها برای داده‌های ترتیبی و پیش‌بینی سری‌های زمانی اعمال می‌شوند و اثربخشی آن‌ها در پردازش وابستگی‌های زمانی را نشان می‌دهند. آزمایشگاه شامل پیاده‌سازی و آموزش RNN‌ها و همچنین تکنیک‌هایی برای بهبود عملکرد و مقابله با چالش‌های متداول است.

¹ Be Fine-Tuned

نتیجه‌گیری

یادگیری عمیق نمایانگر یک پیشرفت مهم در یادگیری ماشین است و ابزارهای قدرتمندی برای پردازش داده‌های پیچیده و با ابعاد بالا ارائه می‌دهد. در حالی که در حوزه‌های خاص بسیار موثر بوده است، کاربرد آن باید با دقت بر اساس مشکل موجود و منابع در دسترس ارزیابی شود. روش‌های سنتی همچنان ارزشمند هستند و انتخاب مدل باید بر اساس عملکرد تجربی و ملاحظات عملی هدایت شود. با درک اصول و تکنیک‌های مطرح شده در این فصل، کارورزان می‌توانند از نقاط قوت یادگیری عمیق برای توسعه راه‌حل‌های نوآورانه برای طیف گسترده‌ای از کاربردها استفاده کنند.